


DS MINI PROJECT · DAY 1

ESS 배터리 수명 예측

초기 충·방전 데이터 기반 EDA와 모델 설계 전략

MIT-Stanford Battery Dataset · Batch 1

울산캠퍼스 3반 | 김대훈



분석 목표와 DAY 1의 의사결정 범위

모델을 먼저 정하지 않고, EDA 증거로 피처와 후보 모델을 좁힌다.

분석 셀

46개

Batch 1 전체

초기 관측 구간

10 → 100

사이클 기반 피처

예측 Target

Cycle Life

EOL까지 총 사이클

최종 Test

Batch 2

DAY 2에서 1회 평가

DAY 1에서 결정할 것

- 수명과 연관된 초기 신호를 통계적으로 확인
- 중복을 제거한 피처 후보와 생성 근거 정리
- 데이터 특성에 맞는 모델 후보와 검증 방식 제시

데이터 사용 원칙

- Batch 1: EDA, 피처 선택, 내부 검증
- Batch 2: 모델과 피처 확정 후 최종 성능 평가
- Knee point 등 미래 정보는 EDA 해석에만 사용

Classification 대신 Regression을 선택

클래스 불균형으로 인한 평가 왜곡을 피하고 연속적인 수명 정보를 모두 활용한다.

Cycle Life 범위

534 - 1,227

연속적인 수명 차이

550 기준 클래스

1 : 45

단수명 1개 / 장수명 45개

다수 클래스 비율

97.8%

모두 장수명 예측 시 정확도

Classification

- Target: 장수명 / 단수명
- 550사이클 미만이 단 1개
- Accuracy가 실제 분류력을 과대평가


Regression

- Target: 연속형 cycle_life
- 모든 셀의 수명 차이를 학습에 활용
- 교체 시점 계획에 직접 활용 가능

최종 선택 | Regression · 평가 지표 MAPE · 원논문 목표 9.1%

초기 100사이클에서 수명 신호를 찾는 분석 흐름


수명 분포·열화· ΔQ ·충전 조건에서 확인한 결과를 피처 선택과 Ridge 전략으로 연결한다.



판단 기준

도메인 타당성 + 효과 크기 + 통계 유의성 + 다중공선성 + 교차검증 안정성

Cycle Life 분포가 태스크 선택을 결정한다



중앙값
858.5 cycles

수명 범위
534 - 1227

550 기준 클래스
1 : 45
단수명 1개 / 장수명 45개

그래프 해석 | 중앙값 858.5, 범위 534-1,227로 연속적인 수명 차이가 존재한다.

선정 Target | 550 기준 단수명은 1개뿐이므로 cycle_life 회귀를 선택한다.

초기 방전 용량을 QD_slope로 요약

원본에 없는 파생 변수이며, Cycle 10~100의 방전 용량 변화를 사이클당 평균 기울기로 변환한다.

원본 데이터

QD_10, QD_100




1. 용량 차이

→ QD_100 - QD_10

2. 관측 간격

→ 100 - 10 = 90 cycles

3. 파생 변수

→ $QD_slope = (QD_{100} - QD_{10}) / 90$ 

파생 변수 선정 · QD_slope

 $\rho = 0.613 \cdot p = 6.04e-06$

초기 90사이클만 사용해 미래 정보 누수 방지

선정 근거

감소가 완만할수록 수명 증가
방향·크기를 한 수치로 요약

EDA 전용 · knee_cycle

수명 후반 정보를 포함해 모델에서 제외
관계 해석에만 사용

원본 방전 곡선을 dQ_log_var로 압축

원본에 없는 파생 변수이며, Cycle 10과 100의 전압별 용량 차이를 한 개의 수치로 요약한다.

원본 데이터

Qdlin_10(V), Qdlin_100(V)



1. 곡선 차이

→ $\Delta Q(V) = Q_{100}(V) - Q_{10}(V)$

2. 변동성 요약

→ $\text{Var}(\Delta Q(V))$

3. 로그 변환

→ $dQ_log_var = \log_{10}(\text{Var})$ 

파생 변수

dQ_log_var

 $\rho = -0.871 \cdot p = 3.48e-15$

선택 근거

- 수명과 가장 강한 단조 관계
- 1,000개 곡선 값을 1개로 압축
- 로그 변환으로 크기 차이 완화


중복 제거

dQ_min:area는 $|p| = 0.97 \sim 1.00$,

VIF 최대 147.9로 대표값에 통합

충전 정책별 수명 차이를 비모수 검정으로 확인

cycle_life는 연속형, 충전 정책은 3개 이상 집단이며 집단 n=1~3으로 작아 Kruskal-Wallis 검정을 적용했다.



초기 C-rate

$$\rho = -0.483$$

$p = 0.0007$

원본 추출 변수 · c_rate_1

- 초기 충전 속도 사용
- 전환 SOC 포함
- 정책 문자열은 수치형으로 분해


Kruskal-Wallis

$$H = 40.15 \cdot p = 0.010$$

정책별 분포 차이 유의

집단 n=1~3: 탐색적 해석

강한 신호와 강한 중복이 동시에 존재한다



발견

- ΔQ 통계량끼리 거의 동일한 정보
- QD_diff와 QD_slope도 완전 중복
- chargetime_10·100 상관 0.99

원본 추출 변수 · chargetime_10

- 초기 충전 거동 정보 유지
- 보조 후보: IR_slope·Tmax_10
- VIF와 축소 OLS로 재검증
- 중복 변수는 대표값만 유지

가설 검정 결과를 모델 설계 근거로 변환

p-value뿐 아니라 효과 크기, 표본 구조, 누수 가능성을 함께 판단한다.

가설	확인 내용	객관적 근거	모델링 시사점
H1	Cycle Life의 정규성을 확인	Shapiro p=0.064	정규성 기각 못함; 잔차 재검토
H2	초기 QD 변화는 수명과 관련	$\rho = 0.613$ / $p < 0.001$	QD_slope 후보
H3	ΔQ 변동이 크면 수명이 짧다	$\rho = -0.871$ / $p < 0.001$	dQ_log_var 핵심
H4	충전 정책별 수명 분포가 다르다	K-W H=40.15 / $p = 0.010$	C-rate 포함; 소표본 주의
H5	초기 피쳐들은 서로 중복된다	ΔQ ρ ≥ 0.97 / VIF $\uparrow$	대표 피쳐만 유지

결론 | 회귀를 선택하고, ΔQ 대표 피쳐 + 초기 열화율 + 충전 조건의 조합을 우선 검증한다.

충전 정책을 분석 단위로 두 가설을 추가 검증

반복 셀을 독립 표본으로 세지 않도록 같은 충전 정책의 셀을 중앙값으로 집계했다: 46개 셀 → 23개 정책.

H1 · ΔQ 와 수명

귀무가설 H0

정책 수준의 dQ_log_var 와 $cycle_life$ 는 독립이다.

검정 방법

Spearman + 19,999회 양측 permutation + 5,000회 bootstrap

H2 · 조정 C1

귀무가설 H0

$\log(cycle_life) \sim C1 + C2 + \text{전환 SOC}$ 에서 C1 계수는 0이다.

검정 방법

정책별 중앙값 OLS + HC3 이분산 강건 표준오차, 양측 검정

H1 결과 | H0 기각

$$\rho = -0.894 \quad \text{permutation } p < 0.001$$

bootstrap 95% CI [-0.968, -0.710]

충전 정책을 분석 단위로 보아도 ΔQ 변동이 클수록 수명이 짧은 관계가 유지된다.

H2 결과 | H0 기각, 탐색적 해석

$$\beta (C1) = -0.256 \quad \text{HC3 } p < 0.001 \cdot R^2 = 0.641$$

C1-SOC Spearman $\rho = -0.869$ · condition number = 809

C2-SOC 조정 후에도 C1은 음의 계수지만, 공선성으로 계수 안정성은 주의한다.

해석 한계 | 인과 효과가 아닌 Batch 1 내 관련성 검증이며, Batch 2 외부 검증이 필요하다.

최종 우선 입력 피처 4개를 선정

서로 다른 열화·충전 정보를 담으면서 중복이 적은 변수만 Ridge 입력 후보로 남긴다.

파생 변수

dQ_log_var

ΔQ 곡선 변동성

$\rho = -0.871$

파생 변수

QD_slope

$(QD_{100} - QD_{10}) / 90$

$\rho = 0.613$

원본 추출

chargetime_10

Cycle 10 충전시간

$\rho = 0.630$

원본 추출

c_rate_1

충전 정책의 1차 C-rate

$\rho = -0.483$

보조 후보

IR_slope · Tmax_10

Batch 1 CV에서 MAPE 개선 시에만 추가

제외 / 통합

dQ_min·area $\rightarrow$ dQ_log_var | QD_diff $\rightarrow$ QD_slope

knee_cycle $\rightarrow$ 미래 정보 누수로 제외

다중공선성을 근거로 Ridge를 우선 후보로 선정

ΔQ 파생 피처의 강한 상관과 $n=46$ 소표본을 고려해, L2 규제로 계수를 안정화하는 Ridge가 가장 적합하다.

EDA 결과

- 표본 46개, 수치형 피처 중심
- Target은 연속형 cycle_life
- ΔQ 와 수명 간 강한 상관관계
- ΔQ 파생 피처의 높은 공선성
- 분류는 1:45로 심각한 불균형

입력 설계

- Target: cycle_life 회귀
- dQ_log_var 대표 피처
- QD_slope·chargetime·C-rate
- 중복 피처 제거 후 표준화
- K-Fold CV + Grid Search

우선 모델

Ridge Regression

- L2 규제로 계수 크기 축소
- 다중공선성의 계수 불안정 완화
- 소표본에서 분산과 과적합 감소
- 모든 피처를 유지해 해석 가능

DAY 1 | Ridge 우선 후보

DAY 2 | CV 성능으로 최종 확정

제외 근거

Tree·Random Forest·XGBoost 계열: $n=46$ 에서 분기 학습과 튜닝에 따른 과적합 위험이 큼

선정 절차: 표준화 → K-Fold CV → Grid Search로 α 탐색 → MAPE·RMSE· R^2 확인

참고문헌 및 분석 산출물

참고문헌

- Severson et al. (2019). Data-driven prediction of battery cycle life before capacity degradation. Nature Energy, 4, 383-391.
- MIT-Stanford Battery Dataset: Batch 1 (2017-05-12), Batch 2 (2018-02-20).
- 20-MLDL 강의 맵: Linear/Ridge/Lasso, K-Fold CV, Grid Search, MAPE·RMSE·R².

재현 가능한 산출물

- 00_data_preparation.ipynb: MAT 구조 확인과 셀 단위 피처 추출
- 01_day1_eda_model_strategy.ipynb: 5개 EDA 질문, 가설 검정, OLS·VIF·규제 회귀
- results/feature_selection.csv: 피처별 통계 및 선택 근거